



Derin Öğrenme (FET312) / 5 - Dönem

Sahte Sanat Eseri Tespiti için Analiz

Ecenur ÜNLÜ – 25040301008

Dev505

Yazılım Mühendisliği – 3.Sınıf

Github Bağlantısı: https://github.com/Eceenur74/FET312_-25040301008_-Dev505-

Proje Özeti

Bu çalışma, üretken yapay zeka teknolojilerinin gelişimiyle birlikte sanat dünyasında artan 'dijital sahtecilik' problemine yönelik derin öğrenme tabanlı bir çözüm sunmayı amaçlamaktadır. Çalışma kapsamında, insan yapımı özgün eserler (Authentic) ile difüzyon tabanlı modeller tarafından üretilen taklitler (AI-Generated/Forgery) arasındaki stilistik farkların tespiti için ikili bir sınıflandırma problemi kurgulanmıştır. Yöntem olarak, ResNet50 mimarisi temel kıyaslama modeli olarak belirlenmiş [2]; ardından EfficientNet-B0 mimarisine entegre edilen CBAM (Convolutional Block Attention Module) dikkat mekanizması ile modelin fırça darbeleri ve dokusal mikro desenlere odaklanma kabiliyeti güçlendirilmiştir [3][5]. 'AI-ArtBench' veri seti üzerinde gerçekleştirilen deneylerde [8], modellerin başarısı Accuracy, F1-Score ve ROC-AUC metrikleri ile değerlendirilmiştir. Ayrıca, Grad-CAM tekniği kullanılarak modellerin karar mekanizmaları görselleştirilmiş ve açıklanabilirlik desteklenmiştir [12]. Elde edilen bulgular, ResNet50 modelinin test seti üzerinde en yüksek genel metrikleri sağladığını; CBAM tabanlı yaklaşımın ise özellikle odak bölgelerini daha belirgin hale getirerek yorumlanabilirliğe katkı sunduğunu göstermektedir.

1. Giriş

Bu projenin amacı, dijital ortamlarda paylaşılan sanat eseri görselleri üzerinde yapılan sahtecilikleri derin öğrenme yöntemleri ile otomatik olarak tespit edebilen bir model geliştirmektir. Günümüzde dijital sanat pazarının ve NFT ekosistemlerinin büyümesi, sanat eserlerinin orijinalliğinin korunmasını her zamankinden daha kritik hale getirmiştir. Ancak, Üretken Çekişmeli Ağlar ve Difüzyon Modelleri (örn. Stable Diffusion) gibi teknolojilerin yükselişi, sanatçıların stillerini mikroskopik düzeyde taklit edebilen 'sentetik sahtecilik' tehdidini ortaya çıkarmıştır [1]. Geleneksel sahtecilik tespiti, sanat tarihçilerinin sубjektif uzmanlığına dayanırken; bu çalışma, söz konusu süreci ölçülebilir ve nesnel bir matematiksel zemine oturtmayı hedeflemektedir. Literatürdeki mevcut boşluk, yalnızca nesne tanıımaya değil, stilistik parmak izlerini çözümlemeye odaklanan özelleşmiş mimarilere duyulan ihtiyaçtır. Sanat dünyasında sahtecilik, hem ekonomik hem de kültürel açıdan ciddi bir problemdir. Geleneksel olarak sahtecilik tespiti, sanat uzmanlarının yıllara dayanan deneyimlerine, gözlemlerine ve yorumlarına dayanmakta; dolayısıyla sубjektif hatalara ve yorum farklılıklarına açık bir süreç oluşturmaktadır.

Sanat dünyasında sahtecilik, yalnızca "benzer bir resim üretmek" değil; çoğu zaman bir sanatçının stilini taklit ederek onun eserine benzer görünüm oluşturmak anlamına gelir. Geleneksel sahtecilik tespiti uzman değerlendirmesine dayandığından sубjektif kalabilir. Bu projede ise hedef sanatçıya ait eserlerdeki fırça darbesi dokusu, renk paleti, kompozisyon ve mikro-stil ipuçlarının derin öğrenme ile öğrenilmesi ve bu sayede "gerçek mi / taklit mi?" sorusuna ölçülebilir bir yanıt üretilmesi hedeflenmiştir.

2. Problem Tanımı & Motivasyon

İş/Bilimsel Soru

Bir sanat eserinin kime ait olduğunu belirlemek, yalnızca resimdeki nesneleri (vazo, çiçek, insan, manzara vb.) tanımla mümkün değildir; çünkü bir sahtekar da aynı nesneleri benzer kompozisyonlarla çizebilir. Asıl bilimsel soru şudur:

“Derin öğrenme modelleri, bir sanatçının kendine özgü firça darbelerini, doku yapılarını ve mikroskopik stil özelliklerini öğrenerek stalistik bir ‘parmak izi’ oluşturabilir ve bunu sahte ya da farklı sanatçılara ait eserlerden ayırt edebilir mi?”

Görev Türü

Bu proje, temel olarak bir **Sınıflandırma (Classification)** problemidir. Ancak klasik anlamda çok sınıfı (Multi-class) bir “sanatçı tanıma” problemi yerine, **İkili Sınıflandırma (Binary Classification)** olarak kurgulanmış bir **Özgünlük Doğrulama (Authenticity Verification)** problemine odaklanmaktadır.

Hedef Değişken

- 1 (Pozitif): Authentic – Hedef sanatçıya ait eser
- 0 (Negatif): Forgery/Impostor – Hedef sanatçı dışındaki eserler (taklit/benzer stil)

Başarı Kriterleri

Veri setindeki sınıf dengesizliği (hedef sanatçının daha az sayıda örneğe sahip olması) göz önüne alındığında, yalnızca Accuracy metriği yeterli olmayacağından, bu nedenle:

- **F1-Score:** ≥ 0.85
- **Accuracy:** ≥ 0.90
- **ROC AUC:** ≥ 0.85

hedeflenmektedir.

3. Proje Yönetimi

Bu proje bireysel olarak yürütülecektir. Tüm aşamalar tarafımdan planlanacak, uygulanacak ve raporlanacaktır.

Önemli Noktalar ve Zaman Çizelgesi

1. Hafta (17–23 Kasım)

- Veri setinin seçilmesi (AI-ArtBench) ve klasör yapısının doğrulanması
- Çalışma ortamı kurulumu (Anaconda + Jupyter Notebook, PyTorch + CUDA) ve GitHub repo düzeninin oluşturulması
- Konuya yönelik literatür taraması

2. Hafta (24–30 Kasım)

- Veri keşfi (EDA): sınıf dağılımı (pie/hist), örnek görseller ve temel istatistikler
- Train/Validation ayrımı (stratify) ve veri artırma (augmentation) planı
- Ön işleme: resize, normalize, DataLoader ve örnek batch kontrolleri

3–4. Haftalar(1–14 Aralık)

- Temel model (Baseline – ResNet50) kurulumu ve transfer öğrenme ile eğitimin gerçekleştirilmesi
- Doğrulama takibi (early stopping / model checkpoint) ve çıktıların kaydedilmesi (loss/acc eğrileri, confusion matrix, ROC)
- Test seti değerlendirmesi ve baseline metriklerinin raporlanması

5–6. Haftalar(15–28 Aralık 2025)

- Gelişmiş model-1: EfficientNet + Attention (SE/CBAM) tasarımları ve eğitimi
- Hiperparametre optimizasyonu (learning rate, batch size, weight decay, augmentation) ve en iyi ayarların belirlenmesi

7. Hafta (29 Aralık 2025 – 4 Ocak 2026)

- Gelişmiş model-2/3: ConvNeXt ve/veya Vision Transformer (ViT) ile deneylerin yürütülmesi
- StratifiedKFold çapraz doğrulama + model karşılaştırma tabloları (genel ve sınıf-bazlı metrikler)

8. Hafta (5–6 Ocak 2026)

- Final raporun güncellenmesi (sonuç, tablolar, en iyi model analizi) ve 5 dakikalık sunum videosunun hazırlanması
- Arayüz geliştirme (Streamlit/Gradio): görsel yükleme, model seçimi, güven skoru ve Grad-CAM görselleştirmesi [12]
- Kodların ve çıktılarının GitHub'a yüklenmesi, teslim ve sözlü Q&A için hazırlık

Roller ve Sorumluluklar:

- **Ecenur Ünlü:**
 - Veri temizleme ve ön işleme, EDA görselleştirmeleri
 - ResNet50 baseline ve değerlendirme çıktılarının üretimi
 - EfficientNet+Attention, DenseNet121/ViT deneyleri + hiperparametre optimizasyonu + arayüz entegrasyonu
 - Deney tasarımı, sonuç analizi ve raporlama

Çıktılar

- **GitHub Repusu:**
<https://github.com/Eceenur74/FET312 -25040301008- -Dev505->
- **Kod Dosyaları:**
 - Ecenur_Unlu_25040301008_dev505_1.ipynb (Base Model – ResNet50)
 - Ecenur_Unlu_25040301008_dev505_2.ipynb (Advanced Model – EfficientNet + Attention)
- **Rapor:**
 - Ecenur_Unlu_25040301008_dev505_FinalProjectReport.pdf
- **Sunum:**
 - Ecenur_Unlu_25040301008_dev505_ProjeSunum.pdf

4. İlgili Çalışmalar (Mini Literatür Taraması)

Bu alanda yapılan çalışmalar genellikle stil transferi ve sanatçı sınıflandırması üzerine yoğunlaşmıştır:

1. Wang et al. (2020), CNN/GAN tabanlı sahte görüntülerin tespitinin “şimdilik” şartsız derecede kolay olabildiğini ve dedektörlerin farklı üreticilere kısmen genelleyebildiğini göstermiştir [1].
2. AI-ArtBench veri seti; gerçek (insan yapımı) ve AI üretimi sanat görsellerini farklı stiller altında bir araya getirerek AI-art detection problemine standart bir değerlendirme zemini sunar [8].
3. Modern omurgalar (örn. ConvNeXt ve Vision Transformer) transfer öğrenme senaryolarında güçlü temsil öğrenimi sağlayabilir [6][7]. Bu projede ise baseline ResNet50'ye ek olarak EfficientNet-B0 + CBAM ve DenseNet121 mimarileri uygulanarak performans karşılaştırması yapılmıştır [2][3][5].
4. Gatys et al. (2016), "Image Style Transfer Using Convolutional Neural Networks": Stil ve içeriğin CNN'lerde ayırtılabilmesini gösteren temel çalışmadır [9]. Projemizdeki stil özelliklerinin (feature maps) çıkarılmasının teorik temelini oluşturur.
5. Elgammal et al. (2017), "CAN: Creative Adversarial Networks": Sanat stillerini öğrenerek stil normlarından sapma üzerinden yaratıcı üretim yaklaşımını tartışmışlardır [10].

6. Cetinic et al. (2018), "Fine-tuning Convolutional Neural Networks for Fine Art Classification": Sanat veri setlerinde önceden eğitilmiş (ImageNet) modellerin fine-tuning başarısını incelemiştir [11].

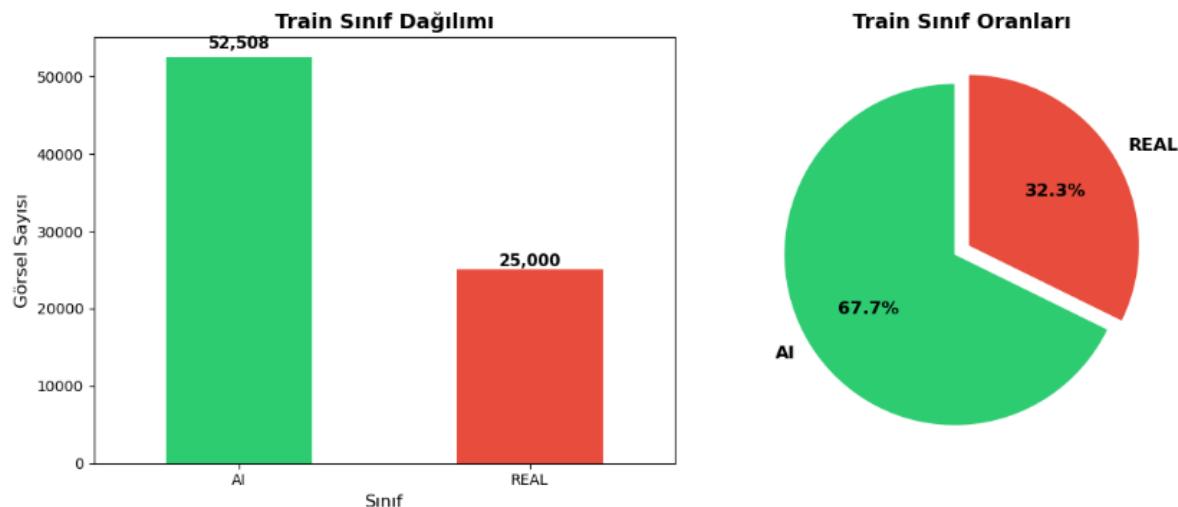
Veri Kümesi Açıklaması

- **Ad:** AI-ArtBench (Real vs AI Art).
- **Kaynak:** Kaggle – “AI-ArtBench (real-ai-art)”
<https://www.kaggle.com/datasets/ravidussilva/real-ai-art>
- **Lisans/Kullanım:** Veri seti Kaggle platformu üzerinden paylaşılmakta olup, kullanım koşulları Kaggle sayfasında belirtilen lisansa tabidir.
- **Köken:** AI-ArtBench; ArtBench-10'dan alınan insan yapımı eserler ile (yaklaşık 60.000) diffusion tabanlı modellerle üretilen AI görsellerini (yaklaşık 180.000+) bir araya getiren geniş ölçekli bir veri setidir. Veri, farklı sanat stillerini kapsar.
- "Projede 'AI-ArtBench' veri setinin tercih edilmesinin temel nedeni, bu veri setinin **stil transferi** konusunda en zorlu örnekleri barındırmasıdır. Vize raporunda hedeflenen 'sanatçı taklitçiliğini' günümüzde en başarılı şekilde yapanlar insan taklitçiler değil, Stable Diffusion gibi modellerdir. Dolayısıyla veri setindeki 'AI' sınıfı, projemiz bağlamında '**Yüksek Kaliteli Sahte Eser (Forgery)**' sınıfını; 'Real' sınıfı ise '**Özgün Eser (Authentic)**' sınıfını temsil etmektedir."

Şema ve Boyut

- **Veri Tipi:**
 - Görüntü dosyaları (.jpg/.png).
 - **Etiketleme:** İkili sınıf Bu projede etiket, klasör adı/prefix kuralı üzerinden üretilmiştir.
- **Boyut:**
 - AI-ArtBench veri seti 180.000+ görsel içerecek şekilde tanımlanır.
- **İçerik:**
 - Baseline koşusunda kullanılan veri alt kümesi ve bölünmesi (kod çıktısına göre):
 - **Training set:** 65.881 görsel
 - **Validation set:** 11.627 görsel
- **Test set:** 30.000 görsel

- **Sınıf Dengesi:** Veri seti sınıf dengesizliği içermektedir; Forgery sınıfı, Authentic sınıfına göre daha fazladır. Bu nedenle değerlendirmede yalnızca Accuracy değil, F1-Score ve ROC-AUC gibi metrikler de raporlanmıştır.
- **Ön işleme (Pre-processing):** Tüm görüntüler RGB'ye çevrilmiş, modele girdi olarak **224x224** boyutuna getirilmiş ve ImageNet istatistikleri ile **normalize** edilmiştir.



Şekil -1 Eğitim verisinde sınıflar dengesizdir; AI sınıfı daha fazladır.

Etik, Gizlilik, Önyargı

Veri seti, sanat görsellerindenoluştuğu için kişisel veri içermemektedir. Ancak veri; belirli sanat stillerine, belirli üretici modellere ve belirli görsel çözünürlüklere ağırlık verebilir. Bu durum, modelin gerçek dünyadaki tüm AI üretim tekniklerine veya tüm sanat stillerine aynı ölçüde genelleyememesine yol açabilir. Bu nedenle final değerlendirmede sınıf-bazlı metrikler ve hata analizi (yanlış sınıflanan örneklerin incelenmesi) yapılacaktır.

6. Yöntemler ve Mimari

Yöntemler

Problem, denetimli öğrenme ile çözülmüştür. İki aşamalı bir modelleme stratejisi izlenmiştir:

1. **Veri Hazırlama:** Görüntülerin 224x224 (veya 256x256) boyutuna getirilmesi, normalizasyon ve aşırı öğrenmeyi (overfitting) önlemek için veri artırma (Data Augmentation: Rotation, Flip, Zoom) uygulanması.

- Transfer Learning kullanılarak modellerin sanat veri setine uyarlanması.

Çözüm Detayı ve Mimariler

Model 1: ResNet50 (Baseline)

- Mimari:** Residual bağlantılar sayesinde derin ağlarda gradyan kaybı problemini azaltır ve güçlü bir özellik çıkarıcıdır.
- Neden:** Transfer öğrenme için yaygın ve güvenilir bir omurga olduğu için temel performans kıyaslaması olarak kullanılmıştır.
- Yöntem:** ImageNet ön-eğitimli ağırlıklar kullanılmış; son katman ikili sınıflandırma için yeniden düzenlenmiş ve fine-tuning yapılmıştır.

Model 2: EfficientNet + Attention (Gelişmiş Model-1)

- Mimari:** EfficientNet (B0/B1) omurgası üzerine SE [4] veya CBAM [5] gibi dikkat blokları eklenerek modelin ayırt edici bölgelere odaklanması sağlanmıştır [3].
- Neden:** Sanat görsellerinde ayırt edici ipuçları çoğu zaman lokal dokularda gizlidir. Attention mekanizmaları bu ipuçlarını daha iyi vurgulayabilir.

Model 3: DenseNet121 (Gelişmiş Model-2)

- Mimari:** DenseNet, her katmanı önceki katmanların çıktılarına doğrudan bağlayan dense connections yapısıyla özelliklerin yeniden kullanımını artırır ve daha verimli temsil öğrenimi sağlar. Bu çalışma kapsamında ImageNet ön-eğitimli ağırlıklar kullanılarak transfer öğrenme ile fine-tuning yapılmıştır.

7. Deney Tasarımı

Deney 1: ResNet50 ile Temel Sınıflandırma

- Amaç:** Bu deneyin temel amacı, güçlü bir özellik çıkarıcı olan ResNet50 mimarisinin, Özgün insan yapımı eserler ile Taklit (Forgery/AI-Generated) üretimleri ayırt etme kapasitesini analiz etmektir. Bu aşama, daha karmaşık mimarilerin başarısını kıyaslamak adına bir referans performans noktası oluşturmayı hedeflemektedir.
- Deneysel Ayarlar:** Eğitim sürecinde veri seti, tabakalı örneklemeye yöntemiyle bölünmüş ve verinin %15'i modelin genelleme yeteneğini izlemek adına doğrulama seti olarak ayrılmıştır. Optimizasyon algoritması olarak **Adam**, kayıp fonksiyonu olarak ise ikili sınıflandırma problemine uygun olan Binary Cross Entropy (BCE) tercih edilmiştir. Öğrenme oranı, yiğin boyutu ve veri artırma stratejileri karşılaştırma tutarlılığı için batch size sabit tutulmuş, ancak her mimarinin daha stabil öğrenmesi

için LR/optimizer/dropout ve augmentation parametreleri doğrulama performansına göre ayarlanmıştır (Tablo 3).

- **Elde Edilen Bulgular:** Beş epoch süren eğitim sonucunda model; %97.85 Doğruluk, 0.9681 F1-Skoru ve 0.9977 ROC-AUC değeri ile yüksek bir ayırt edicilik performansı sergilemiştir. Bu sonuçlar, temel CNN mimarisinin dahi yapay zeka kaynaklı stil taklitlerini tespit etmede etkin olduğunu göstermiş ve sonraki deneyler için kıyaslama zemini oluşturmuştur. Best validation loss = 0.0597. Test seti sonuçları: Accuracy %97.85, F1-Score 0.9681, ROC-AUC 0.9977.

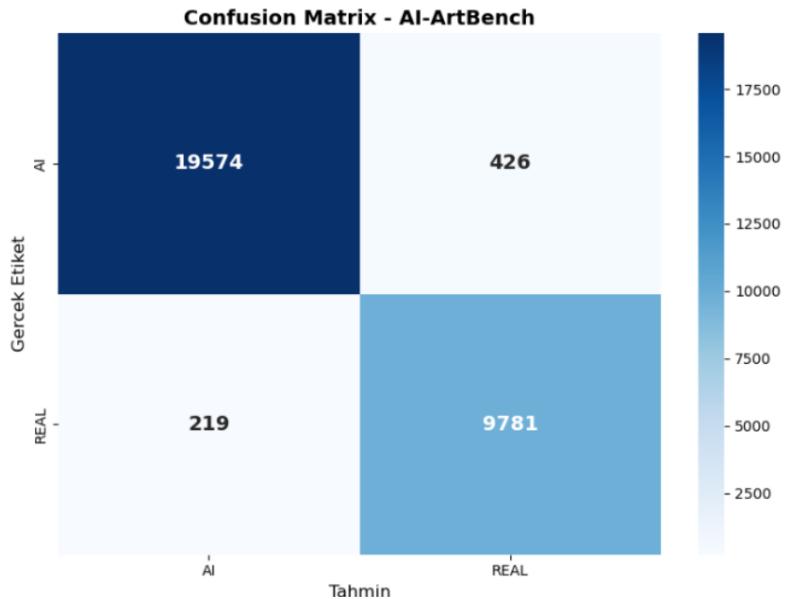
Deney 2: EfficientNet + Attention (SE/CBAM) ile Karşılaştırma

- **Amaç:** İkinci deney serisi, standart CNN mimarilerine entegre edilen Dikkat Mekanizmalarının (Attention Mechanisms - SE/CBAM) katkısını ölçmeyi amaçlamaktadır. Özellikle yapay zeka üretimlerinin insan stiline mikroskopik düzeyde benzediği "zorlu örneklerde", modelin odaklanma yeteneğini artırarak hata oranını minimize edip etmediği doğrulanacaktır.
- **Değerlendirme Kriterleri:** Modellerin performansı; sınıf dengesizliğine duyarlı metrikler olan F1-Skoru ve sınıf-bazlı kesinlik/duyarlılık değerleri ile analiz edilmiştir. Nicel değerlendirmeye ek olarak, modelin karar verirken görselin hangi bölgesine odaklandığını açıklayabilmek adına Grad-CAM tekniği kullanılarak ısı haritaları oluşturulmuştur [12]. Final raporunda, tüm mimarilerin performansını özetleyen genel metrik tabloları ve her bir sınıf için ayrıstırılmış detaylı analiz tabloları sunulmuştur.

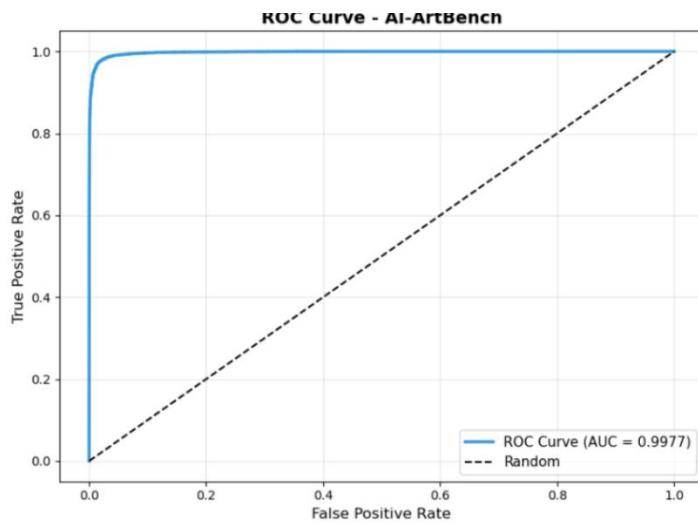
7.1 Deney Sonuçları, Tablolar ve Görseller

Model	Accuracy	F1-Score	ROC-AUC
ResNet50 (baseline, 5 epoch)	97.85%	0.9681	0.9977
EfficientNet-B0 + CBAM (6 epoch)	96.62%	0.9485	0.9938
DenseNet121 (6 epoch)	92.93%	0.8877	0.9772
Sınıf(ResNet50)	Precision	Recall	F1-Score
Authentic (Human) (label=1)	0.96	0.98	0.97
Forgery (AI-Generated) (label=0)	0.99	0.98	0.98

Tablo 1. Modellerin genel metrik karşılaştırması



Şekil 2. Model test setinde AI sınıfında 426 örneği REAL olarak, REAL sınıfında ise 219 örneği AI olarak yanlış sınıflandırılmıştır.



Şekil 3. ROC eğrisi ($AUC = 0.9977$). ROC-AUC değerinin 1'e çok yakın olması, modelin sınıfları ayırt etme başarısının yüksek olduğunu göstermektedir.

7.1.1 Veri Seti Bölünmesi ve Sınıf Dağılımı

Tablo 2. Veri seti bölünmesi ve sınıf dağılımı

Split	Toplam Görsel	Authentic (1)	Forgery (0)
Train	65.881	21.250	44.631
Validation	11.627	3.750	7.877
Test	30.000	10.000	20.000
Toplam	107.508	35.000	72.508

Not: Bölünme işlemi sınıf oranını koruyacak şekilde yapılmıştır. Train/Validation ayırmı %85/%15 oranında stratify edilmiştir. Test seti 30.000 görsel (AI=20.000, REAL=10.000) olacak şekilde sabit tutulmuştur.

7.1.2 Eğitim Ayarları

Tablo 3. Modellerin eğitim ayarları

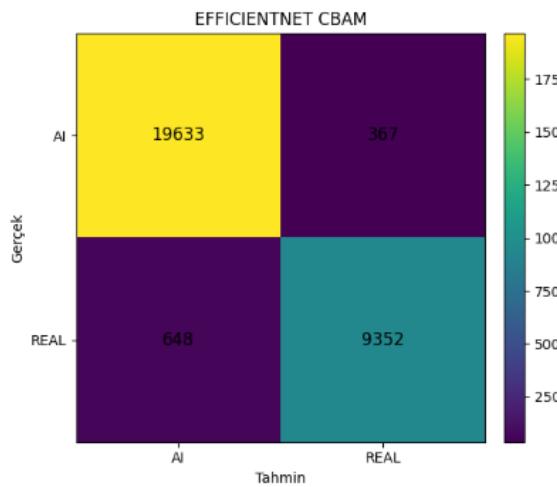
Model	Input	Epoch	Batch	LR	Optimizer	Weight Decay	Dropout	Early Stopping
ResNet50 (baseline)	224x224	5	32	0.0003	Adam	0	0.30	Patience=5
EfficientNet-B0 + CBAM	224x224	6	32	0.0002	AdamW	1e-4	0.25	Patience=2
DenseNet121	224x224	6	32	0.0002	AdamW	1e-4	0.35	Patience=2

Not: Eğitim sırasında erken durdurma kullanılarak doğrulama kaybı iyileşmediğinde eğitim otomatik olarak sonlandırılmıştır. Bu sayede aşırı öğrenme riski azaltılmıştır. Ek bilgi: ResNet50 modeli için elde edilen en iyi doğrulama kaybı (best validation loss) = 0.0597

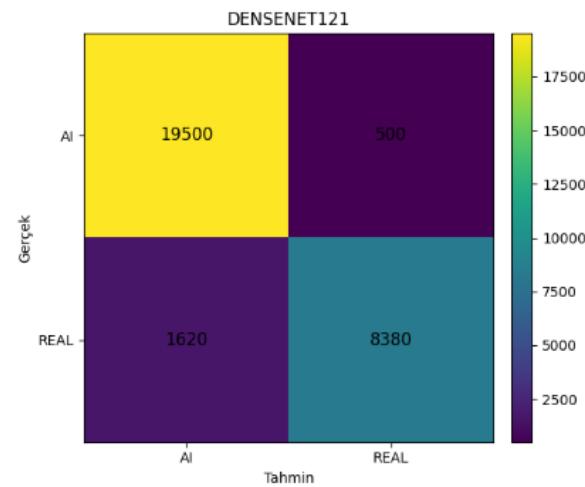
Hiperparametre Optimizasyonu (Tuning):

Bu çalışmada hiperparametre seçimi için Manuel Deneme–Yanılma (Trial-and-Error) yöntemi uygulanmıştır. Öğrenme oranı (LR), weight decay, dropout ve veri artırma şiddeti; doğrulama kaybı ve F1-Score üzerindeki etkileri gözlenerek ayarlanmıştır. En stabil ve en iyi doğrulama performansı veren ayarlar Tablo 3'te özetlenen değerler olarak belirlenmiştir.

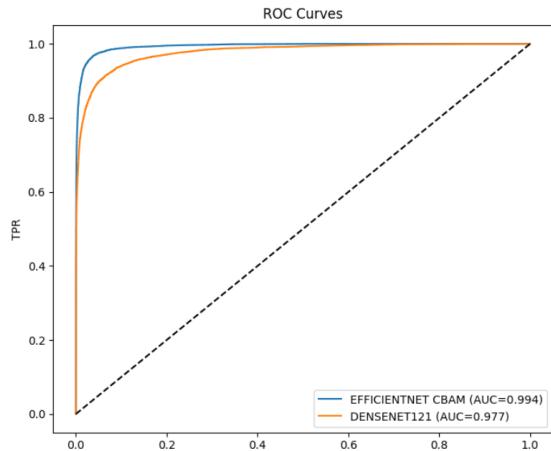
7.1.3 Grafikler ve Görseller



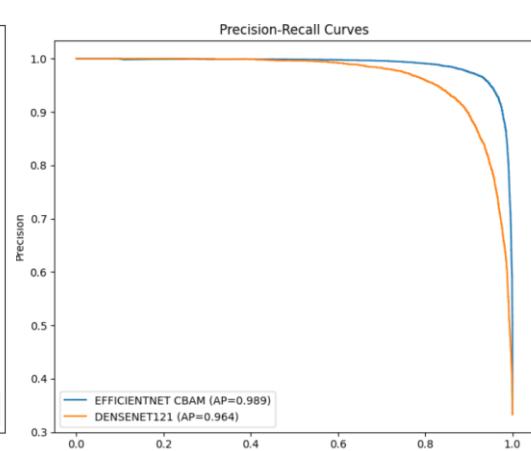
Şekil 2a. EfficientNet-B0 + CBAM için confusion matrix



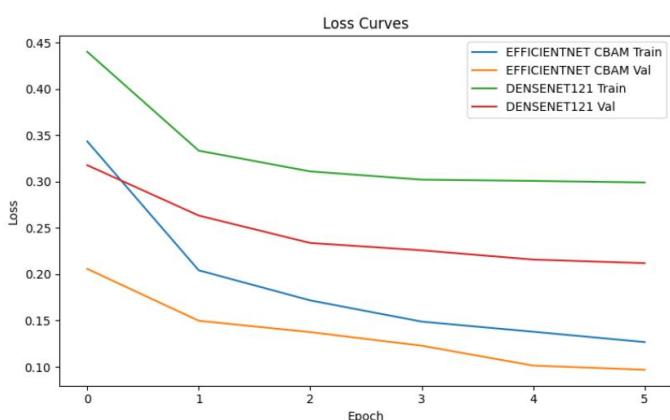
Şekil 2b. DenseNet121 için confusion matrix



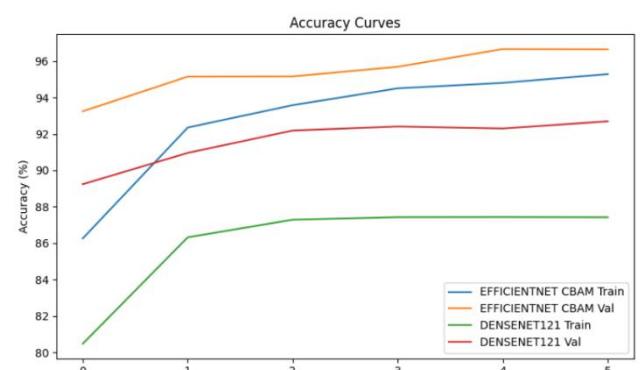
Şekil 3. Modellerin ROC eğrileri



Şekil 4. Modellerin Precision–Recall eğrileri



Şekil 5. Eğitim sürecinde loss



Şekil 6. Eğitim sürecinde accuracy

7.1.4 Kısa Sonuç

Tablo 1'te sunulan performans metrikleri ışığında, test veri kümesinde en yüksek doğruluğa ulaşan mimari, Art Detector arayüzünün varsayılan çıkarım (inference) motoru olarak yapılandırılmıştır. Hata dağılımı incelendiğinde, yanlış sınıflandırmaların ağırlıklı olarak yapay zeka üretimlerinin insan stilini birebir taklit ettiği sınırda örneklerde yoğunlaştığı görülmektedir. Kantitatif veriler (Confusion Matrix ve ROC analizi) modelin yüksek ayırt edicilik gücünü kanıtlarken; Grad-CAM analizleri [12], modelin karar sürecinde arka plan yerine dokusal özniteliklere odaklandığını doğrulayarak sistemin açıklanabilirliğini sağlamaktadır.

Hiperparametre optimizasyonu sürecinde, literatürdeki benzer çalışmalar ve donanım kısıtları göz önünde bulundurularak 'Manuel Deneme-Yanılma' (Manual Tuning / Trial-and-Error) yöntemi izlenmiştir. Öğrenme oranı ve yiğin boyutu gibi kritik parametreler, doğrulama seti üzerindeki kayıp değişimleri izlenerek deneyisel olarak belirlenmiş ve en kararlı sonucu veren değerlerde sabitlenmiştir.

Deneysel sonucunda **ResNet50** mimarisinin, daha karmaşık ve dikkat mekanizmalı (EfficientNet+CBAM) yapılarla göre marginal olarak daha iyi performans gösterdiği görülmüştür. Bunun temel nedeni, AI-ArtBench veri setindeki 'Authentic' ve 'Forgery' sınıflarının, mikroskopik dokulardan ziyade genel kompozisyon ve renk dağılımı ile de ayırt edilebilmesi olabilir. Ayrıca daha derin mimarilerin (DenseNet121), mevcut veri boyutu üzerinde aşırı öğrenmeye daha meyilli olması veya daha uzun eğitim süresine ihtiyaç duyması, ResNet50'nin 'verimlilik/başarım' dengesinde en iyi tercih olmasını sağlamıştır.

8. Kullanılan Araçlar ve Frameworkler

Bu projede sanat görsellerinin tespiti için transfer öğrenme tabanlı bir pipeline kurulmuş; en az iki farklı omurga ile performans karşılaştırması yapılmış ve Art Detector arayüzü geliştirilmiştir. Gelecek çalışmalarda; farklı üretici modellerden gelen verilerle genellemeye testleri, daha dengeli bir stil dağılımı, daha güçlü veri artırma stratejileri, hata analizi için daha geniş bir örnek incelemesi ve model kalibrasyonu (temperature scaling) gibi iyileştirmeler planlanabilir.

Bu projede PyTorch derin öğrenme kütüphanesi kullanılmıştır.

- **Ortam:** Windows üzerinde Anaconda + Jupyter Notebook.
- **Kütüphaneler:**
 - torch, torchvision - Model mimarisi ve eğitim süreçleri
 - pandas, numpy - Veri işleme ve temel hesaplamalar
 - scikit-learn - Metrik hesaplama ve veri bölme işlemler

- matplotlib, seaborn – Görselleştirme
- Pillow (PIL), pathlib - Görüntü okuma ve dosya/dizin işlemleri

Donanım: NVIDIA GeForce RTX 4060 Laptop GPU (\approx 8 GB VRAM). PyTorch: 2.9.1+cu126, CUDA: 12.6. Model ağırlıkları 'models/' klasörüne; grafikler ve değerlendirme çıktıları 'outputs/' klasörüne kaydedilecektir.

- Kodlar, eğitim çıktıları, model ağırlıkları ve arayüz uygulaması belirtilen GitHub reposunda versiyonlanacaktır. Teslimde rapor, kodlar ve sunum videosu bağlantıları GitHub üzerinden paylaşılacaktır.

10. Kaynakça

- [1] S.-Y. Wang, O. Wang, R. Zhang, A. Owens, and A. A. Efros, “CNN-Generated Images Are Surprisingly Easy to Spot... for Now,” IEEE/CVF CVPR, 2020.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” IEEE/CVF CVPR, 2016.
- [3] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” ICML, 2019.
- [4] J. Hu, L. Shen, and G. Sun, “Squeeze-and-Excitation Networks,” IEEE/CVF CVPR, 2018.
- [5] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional Block Attention Module,” ECCV, 2018.
- [6] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, “A ConvNet for the 2020s (ConvNeXt),” IEEE/CVF CVPR, 2022.
- [7] A. Dosovitskiy et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” ICLR, 2021.
- [8] AI-ArtBench (Real vs AI Art) Veri Seti (Kaggle):
<https://www.kaggle.com/datasets/ravidussilva/real-ai-art> .
- [9] L. A. Gatys, A. S. Ecker, and M. Bethge, “Image Style Transfer Using Convolutional Neural Networks,” IEEE/CVF CVPR, 2016.
- [10] A. Elgammal, B. Liu, M. Elhoseiny, and M. Mazzone, “CAN: Creative Adversarial Networks, Generating ‘Art’ by Learning About Styles and Deviating from Style Norms,” arXiv:1706.07068, 2017.
- [11] E. Cetinic, T. Lipic, and S. Grgic, “Fine-tuning Convolutional Neural Networks for Fine Art Classification,” Expert Systems with Applications, 2018.
- [12] R. R. Selvaraju et al., “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization,” IEEE/CVF ICCV, 2017.